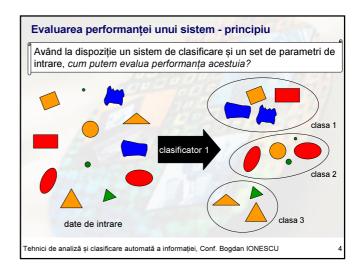
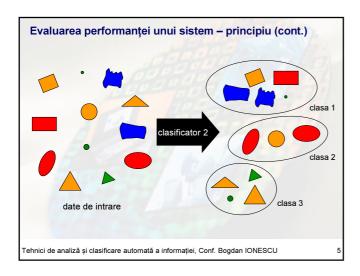
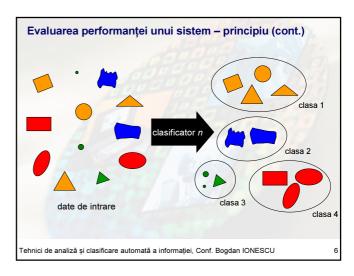
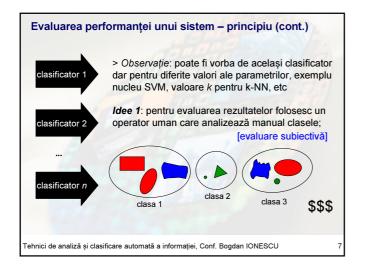


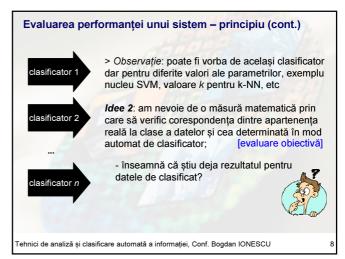
> M5. Evaluarea performanței clasificatorilor
5.1. [Introducere]
5.2. [Măsuri de performanță]
5.3. [Evaluarea performanței]
5.4. [Exemple de sisteme de clasificare]



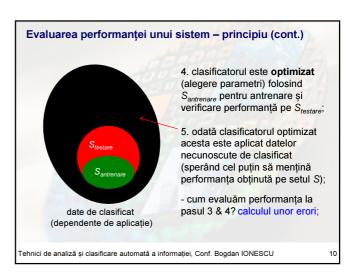


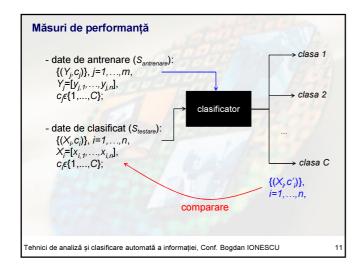


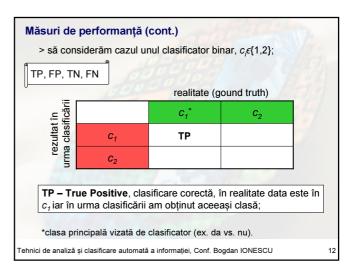


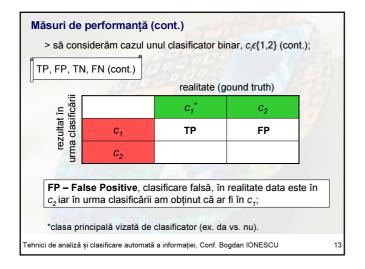


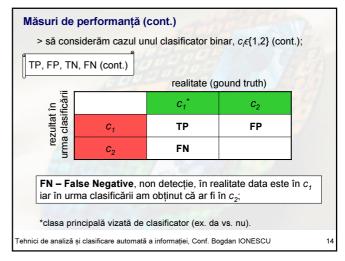


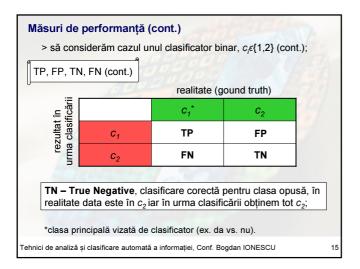


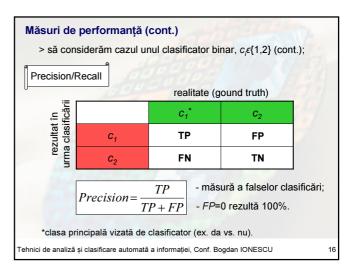


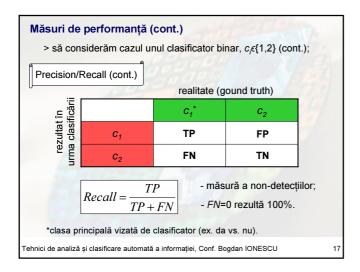


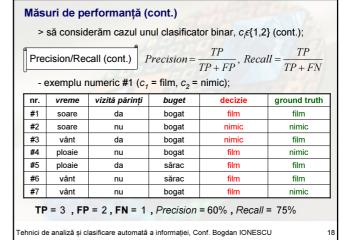












### Măsuri de performanță (cont.)

> să considerăm cazul unul clasificator binar,  $c_i \in \{1,2\}$  (cont.);

Precision/Recall (cont.) 
$$Precision = \frac{TP}{TP + FP}$$
,  $Recall = \frac{TP}{TP + FN}$ 

- exemplu numeric #2 ( $c_1$  = film,  $c_2$  = nimic)

nr.	vreme	vizită părinți	buget	decizie	ground truth
#1	soare	da	bogat	film	film
#2	soare	nu	bogat	film	nimic
#3	vânt	da	bogat	film	film
#4	ploaie	nu	bogat	film	nimic
#5	ploaie	da	sărac	film	film
#6	vânt	nu	sărac	film	film
#7	vânt	nu	bogat	film	nimic

ehnici de analiză și clasificare automată a informației, Conf. Bogdan IONESCU

#### Măsuri de performanță (cont.)

> să considerăm cazul unul clasificator binar,  $c_{\varepsilon}$ {1,2} (cont.);

Precision/Recall (cont.) 
$$Precision = \frac{TP}{TP + FP}$$
,  $Recall = \frac{TP}{TP + FN}$ 

- ce este mai important, precision sau recall'
- ce este mai important să obținem, cât mai puține clasificări false sau cât mai puține non-detecții?
- depinde de aplicație!
- web: ex. sistem de căutare a informației; cât de important este să găsim toate datele de un anumit tip de pe tot Internet-ul?
- · forensics: ex. sistem de căutare a unei persoane pe baza profilului; cât de important este să găsim toate persoanele care corespund profilului căutat?

Tehnici de analiză și clasificare automată a informației, Conf. Bogdan IONESCU

#### Măsuri de performanță (cont.)

> să considerăm cazul unul clasificator binar, c, ɛ{1,2} (cont.);

F-measure

- există o măsură care combină precision și recall într-un mod unitar:

$$F - measure = (1 + \beta^2) \frac{Precision \cdot Recall}{\beta^2 \cdot Precision + Recall}$$

unde β este o constantă:

$$\beta = 1 \Rightarrow FI = 2 \frac{Precision \cdot Recall}{Precision + Recall}$$
 [contribuție egală, medie armonică]

 $\beta$  = 2  $\Rightarrow$  F2 = 5  $\frac{Precision \cdot Recall}{4 \cdot Precision + Recall}$  [pondere mai mare Recall]

Fehnici de analiză și clasificare automată a informației, Conf. Bogdan IONESCU

#### Măsuri de performanță (cont.)

> să considerăm cazul unul clasificator binar, c,ɛ{1,2} (cont.);

Accuracy

rezultat în na clasificării

- o măsură a numărului de clasificări corecte:

realitate (gound truth) FP ΤN

TP + TN- TP + FP + FN + TN = TP + FP + FN + TN numărul total de date;

Tehnici de analiză și clasificare automată a informației, Conf. Bogdan IONESCU

## Măsuri de performanță (cont.)

> să considerăm cazul unul clasificator binar,  $c_i \in \{1,2\}$  (cont.);

Mean Average Precision (MAP)

- o măsură a preciziei medii; spre deosebire the Precision si Recall, MAP tine cont de ordinea în care sunt clasate datele (mai important să avem rezultate corecte în primele rezultate);
- o metrică adaptată unui scenariu de tip "information retrieval" în care rezultatele sunt ordonate în ordinea descrescătoare a asemănării cu datele căutate (echivalent clasă);
- cum poate fi adaptată pentru problema clasificării? [reprezentăm datele clasificate în ordinea descrescătoare a măsurii de încredere ("confidence level") furnizată de clasificator, astfel obtinem o ordonare a acestoral

Fehnici de analiză și clasificare automată a informației, Conf. Bogdan IONESCU

# Măsuri de performanță (cont.)

> să considerăm cazul unul clasificator binar, c, ∈{1,2} (cont.);

Mean Average Precision (MAP; cont.)

$$AP = \sum_{k=1}^{n} P(k) \cdot rel(k)$$

unde #rel reprezintă numărul de date relevante existente în clasa curentă, n reprezintă numărul de date de clasificat, P(k) reprezintă Precision calculat pentru primele k date, rel(k) = 1 dacă data de pe poziția k este relevantă pentru clasă și 0 altfel;

$$MAP = \frac{1}{O} \sum_{q=1}^{Q} AP(q)$$

unde q reprezintă clasele (adoptat din notație  $MAP = rac{1}{Q} \sum_{q=1}^{Q} AP(q)$  unitială unde reprezenta "query") iar Q este numărul de clase în care clasificăm datele.

Tehnici de analiză și clasificare automată a informației, Conf. Bogdan IONESCU

